CS33503: 数据库系统

邹兆年

哈尔滨工业大学
计算机科学与技术学院
海量数据计算研究中心
电子邮件: znzou@hit.edu.cn

2021年春

课程安排

授课班级

- 1803104 (计算机科学与技术/自然语言处理)
- 1803105 (计算机科学与技术/视听觉信息处理)
- 1803106 (计算机科学与技术/视听觉信息处理)
- 1803501 (数据科学与大数据技术)

课堂授课

- 20次课，40学时
- 1–10周，周三3–4节、周五3–4节, 正心44

实验

- 2次实验，8学时
- 6、10周，周日5–8节，格物207、格物214

教学团队

主讲教师

- 邹兆年，教授、博士生导师
- 办公室：科学园科创大厦K1417
- 个人主页：http://homepage.hit.edu.cn/zou
- 电子邮件：znzou@hit.edu.cn
- QQ：12943596

助教

- 1803104班：崔路源、景子奇
- 1803015班：刘振方、王婧媛
- 1803106班：潘超文、李锦江
- 1803501班：王润安、施子腾

在线教学

课程主页

- http://openlearning.hit.edu.cn/course/2496
- 需通过学校VPN访问

QQ群

- 640584056
- 请将群昵称修改为“姓名-学号”

教材与参考书

- Ramez Elmasri and Shamkant B. Navathe. Fundamentals of Database Systems (Fourth Edition)
- Hector Garcia-Molina, Jeffrey D. Ullman, and Jennifer Widom. Database System Implementation (Second Edition)
- Raghu Ramakrishnan and Johannes Gehrke. Database Management Systems (Third Edition)
- Abraham Silberschatz, Henry F. Korth, and S. Sudarshan. Database System Concepts (Sixth Edition)
- Jeffrey D. Ullman and Jennifer Widom. A First Course in Database Systems (Third Edition)

教学大纲

第一部分: 数据库系统基础(10学时) // 如何使用数据库系统

- 第1章: 绪论(1学时)
- 第2章: 关系数据库(3学时)
- 第3章: 结构化查询语言(6学时)

第二部分: 数据库系统设计(10学时) // 如何设计开发数据库系统

- 第4章: 概念数据库设计(3学时)
- 第5章: 逻辑数据库设计(5学时)
- 第6章: 物理数据库设计(2学时)

第三部分: 数据库系统实现(20学时) // 数据库管理系统的原理

- 第7章: 存储管理(4学时)
- 第8章: 查询执行(4学时)
- 第9章: 查询优化(4学时)
- 第10章: 故障恢复(4学时)
- 第11章: 并发控制(4学时)

考核方式

- 考试: 占60%，考试时间待定
- 实验: 占20%
- 作业: 占20%

第1章: 绪论

邹兆年

哈尔滨工业大学
计算机科学与技术学院
海量数据计算研究中心
电子邮件: znzou@hit.edu.cn

2021年春

教学内容[1]

1. 什么是数据管理?
2. 数据库系统的基本概念
3. 数据库系统的宝贵知识财富
   - 数据独立性
   - 数据库语言
   - 索引结构
   - 事务处理
4. 数据库管理系统的组成

[1]课件更新于2021年3月9日

1.1 Data Management

什么是数据?

数据(data): 能够被记录且具有实际含义的已知事实

- "Everest": 世界最高峰的英文名
- 8,848: 世界最高峰的高度(单位: 米)
- 29,029: 世界最高峰的高度(单位: 英尺)
- "Asia": 世界最高峰所在的大洲
-  : 世界最高峰的照片

数据管理(Data Management)

数据管理(data management): 在计算机中对数据进行存储、检索、更新、共享

- 几乎所有应用都需要进行数据管理
- 你管理过数据吗?
- 你用过什么数据管理方法?
- 什么是好的数据管理方法?

基于文件系统的数据管理方法

- 数据存储于文件中
- 数据由应用程序经过文件系统进行管理

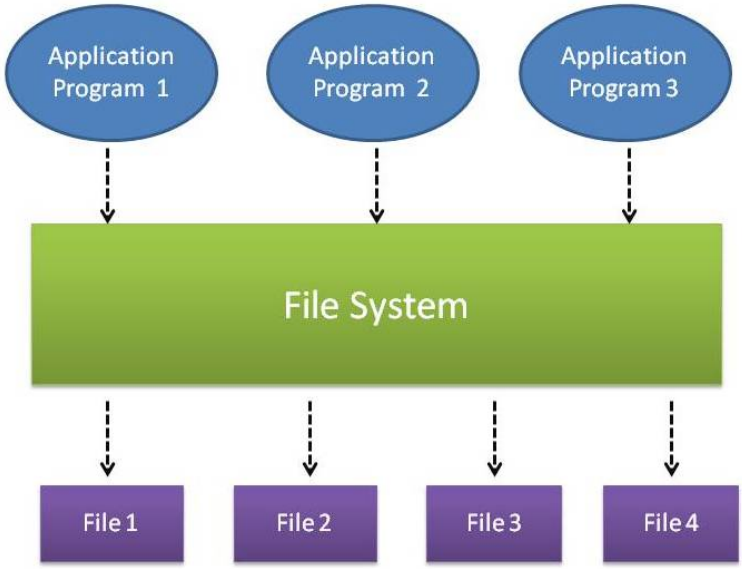

基于文件系统的数据管理方法: 例子

文件:

student.txt

CS-001	Elsa	F	19	CS	Turing
CS-002	Ed	M	19	CS	Turing
MA-001	Abby	F	18	Math	Gauss
MA-002	Cindy	F	19	Math	Gauss
PH-001	Nick	M	20	Physics	Newton

grade.txt

CS-001	1002	95
CS-001	3006	90
CS-002	3006	80
MA-001	1002	
PH-001	1002	92
PH-001	2003	85
PH-001	3006	88

这些查询怎么做?

- 找出计算机系(CS)的所有学生
- 找出选修了1002号课程的学生

方法:

- 编写应用程序
- 使用Linux shell

基于文件系统的数据管理方法的缺点

student.txt

CS-001	Elsa	F	19	CS	Turing
CS-002	Ed	M	19	CS	Turing
MA-001	Abby	F	18	Math	Gauss
MA-002	Cindy	F	19	Math	Gauss
PH-001	Nick	M	20	Physics	Newton

grade.txt

CS-001	1002	95
CS-001	3006	90
CS-002	3006	80
MA-001	1002	
PH-001	1002	92
PH-001	2003	85
PH-001	3006	88

- 每当文件格式发生变化，就要修改应用程序
- 文件中存在冗余数据
- 文件修改可能造成数据不一致
- 文件修改可能破坏数据正确性
- 没有索引，数据访问效率低
- 只能对整个文件进行访问控制，数据安全性差
- 没有并发控制，多个应用程序同时读写文件可能产生冲突

在应用程序中解决上述问题。应用程序员:"我太难了!"

基于数据库管理系统的数据管理方法

- 数据存储在数据库(database)中
- 数据由应用程序经过数据库管理系统(database management systems, DBMS)进行管理

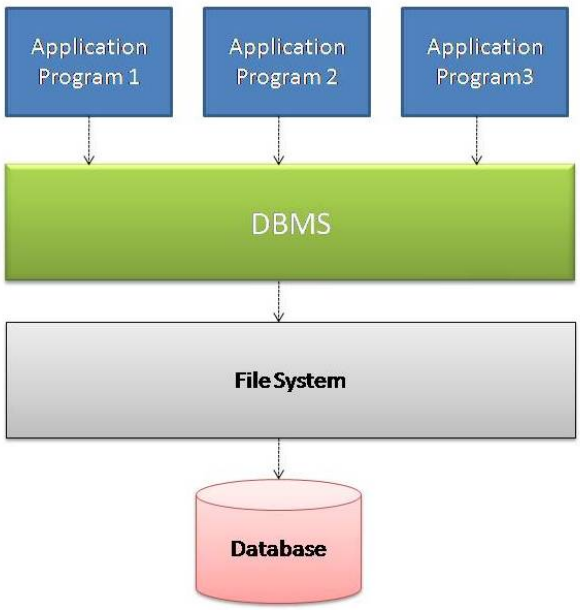

基于文件系统的方法 vs. 基于DBMS的方法

	基于文件系统	基于DBMS的方法
数据冗余度	高	低
数据一致性	No	Yes
数据正确性	No	Yes
索引	No	Yes
访问控制	No	Yes
并发控制	No	Yes
故障恢复	No	Yes

数据管理的功能

- 数据定义(data definition): 定义数据的结构、类型及约束
- 数据存储(data storage): 存储和存取数据
- 数据操纵(data manipulation): 查询数据、更新数据(插入数据、修改数据、删除数据)
- 数据共享(data sharing): 事务管理(transaction management)、并发控制(concurrency control)、故障恢复(failure recovery)
- 数据控制(data control): 保证数据完整性(data integrity)、数据安全性(data security)
- 数据维护(data maintenance): 数据录入、数据转换、数据备份、数据恢复、性能监控

1.2 Database Systems

数据库(Database)

A database (DB) is a set of related data that is organized (组织), shared (共享), and persistent (持久化)

数据库管理系统(DBMS)

A database management system (DBMS) is a general-purpose system software that facilates the organization (组织), storage (存储), manipulation (操纵), control (控制), and maintainence (维护) of databases among various users and application programs.

数据库用户(Database User)

- 数据库管理员(database administrator, DBA): 授权数据库访问，协调和监控数据库使用，获取软硬件资源，控制资源的使用，监控数据库性能
- 数据库设计者(database designer): 负责定义数据库的内容、结构、约束、存储过程和事务
- 终端用户(end user): 查询数据库，生成报表，部分终端用户还可以修改数据库内容

数据库系统(Database System)

数据库系统(database system, DBS)是由数据库、数据库管理系统、应用程序和数据库用户在一起构成的系统

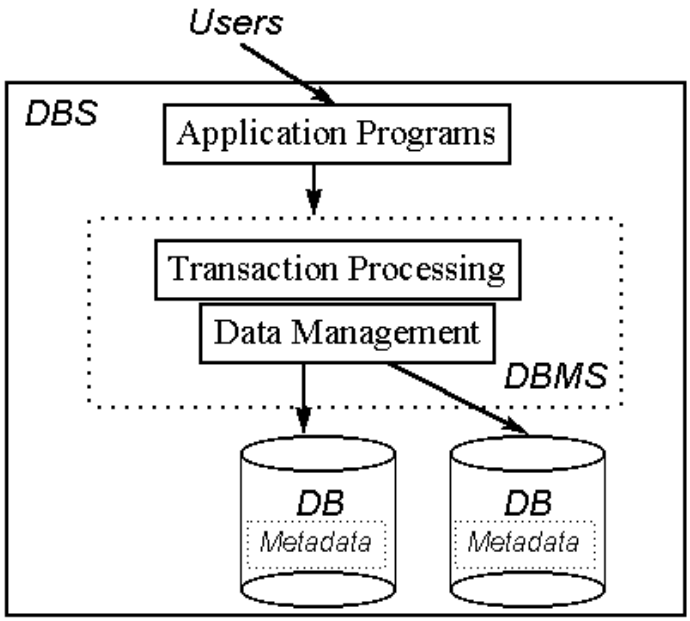

学习数据库系统的重要性

- 当你得到一个数据库，并需要对它进行管理时，你需要了解数据库系统的基本概念，掌握数据库语言，具备数据库系统的使用技能。
- 当你面对一个数据密集型应用设计与开发需求时，你需要掌握数据库的设计方法，了解如何评估设计方案的优劣，具备数据库系统应用开发能力。
- 当你接手一个性能低下的数据密集型应用时，你需要了解数据库系统的工作原理，知道如何对系统进行优化和重新设计。
- 当你参与一种新型数据库管理系统的研发时，你需要了解多种数据库管理系统的工作原理和设计方案，并具备一定的研究能力。

1.3 Data Independence

数据抽象(Data Abstraction)

数据抽象(data abstraction)是将现实世界映射到计算机世界的过程

现实世界 $\longrightarrow$ 信息世界 $\longrightarrow$ 计算机世界

- 现实世界: 张三、李四、数学系、物理系、高等数学、大学物理...
- 信息世界: 实体、属性、联系、约束...
- 计算机世界: 记录、域、引用...

数据模型(Data Model)

数据模型(data model)是完成数据抽象的工具

数据模型的三要素

1. 用于描述数据库的结构的一系列概念
2. 用于操纵数据结构的一系列操作
3. 数据库应当服从的约束条件

数据模型的分类

- 概念数据模型(conceptual data model): 该模型提供的概念最接近用户理解数据的方式，用于将现实世界映射到信息世界(第4章讲)
- 物理数据模型(physical data model): 该模型提供的概念用于描述数据库在计算机中的存储细节(第7章讲)
- 实现数据模型(implementation data model): 该模型处在概念数据模型和物理数据模型之间，在实现DBMS时使用
  - 层次数据模型
  - 网络数据模型
  - 关系数据模型(本课程学习的实现数据模型, 第2章讲)
  - 面向对象数据模型
  - XML数据模型
  - 文档数据模型
  - 图数据模型

  在将信息世界映射到计算机世界时，要用到实现数据模型和物理数据模型

现实世界 $\xrightarrow[model]{conceptual}$ 信息世界 $\xrightarrow[model]{implementation}$ $\xrightarrow[model]{physical}$ 计算机世界

数据库模式(Database Schema)

数据库模式(database schema)是对数据库的结构、类型、约束的描述

- 数据库模式是数据库的“类型声明”
- 数据库模式不经常变化

Student关系模式

Sno	Sname	Ssex	Sage	Sdept

数据库实例(Database Instance)

数据库实例(database instance)是数据库在某一特定时间存储的数据

- 数据库实例是数据库的“值”
- 每当数据库被更新，数据库实例就发生变化

Student关系实例

Sno	Sname	Ssex	Sage	Sdept
PH-001	Nick	M	20	Physics
CS-001	Elsa	F	19	CS
CS-002	Ed	M	19	CS
MA-001	Abby	F	18	Math
MA-002	Cindy	F	19	Math

数据库的三层模式结构(Three-Schema Architecture)

数据库不是只用一种模式来描述的，数据库模式分三个层次来定义

内模式(Internal Schema)/存储模式(Storage Schema)

- 描述数据库的物理存储结构和存取方法
- 数据库只有一个内模式
- 定义内模式时通常使用物理数据模型提供的概念

概念模式(Conceptual Schema)

- 为全体数据库用户描述整个数据库的结构和约束
- 数据库只有一个概念模式
- 定义概念模式时使用实现数据模型提供的概念

外模式(External Schema)/视图(View)

- 从不同类别用户的视角描述数据库的结构
- 数据库可以有多个外模式
- 定义外模式时也使用实现数据模型提供的概念

数据库的三层模式结构(Three-Schema Architecture)

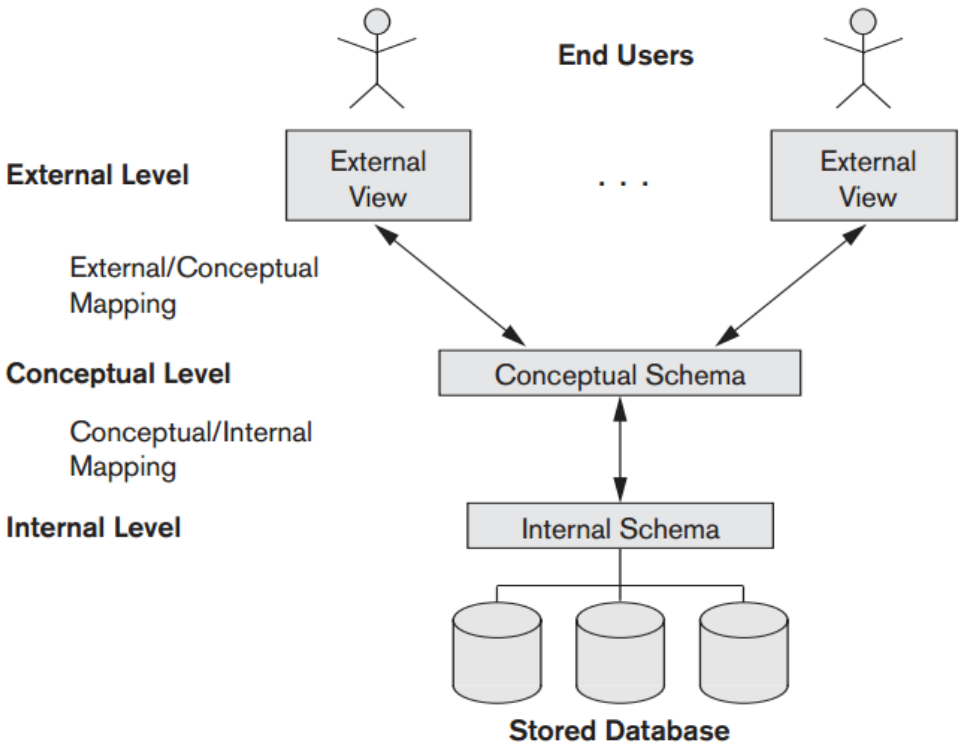

模式映射(Schema Mapping)

在三层模式结构中，不同层次模式间的映射用于完成应用程序与数据库之间的数据转换(data transformation)和请求转换(request transformation)

- 请求转换: 应用程序是依据外模式开发的，应用程序在外模式上声明的数据请求通过模式映射转换为DBMS在内模式上的请求
- 数据转换: 数据库的物理存储是按照内模式来组织的，DBMS检索到的数据通过模式映射转换为符合外模式的组织形式，返回给应用

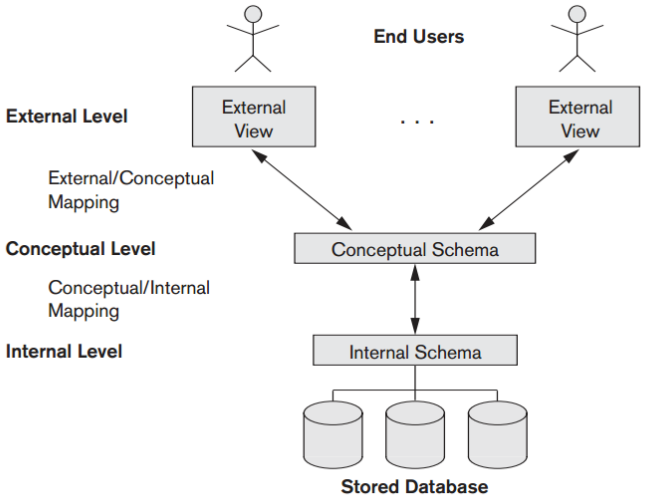

模式映射的分类

- 外模式-概念模式映射(external/conceptual mapping): 从一个外模式到概念模式的映射
- 概念模式-内模式映射(conceputual/internal mapping): 从概念模式到内模式的映射

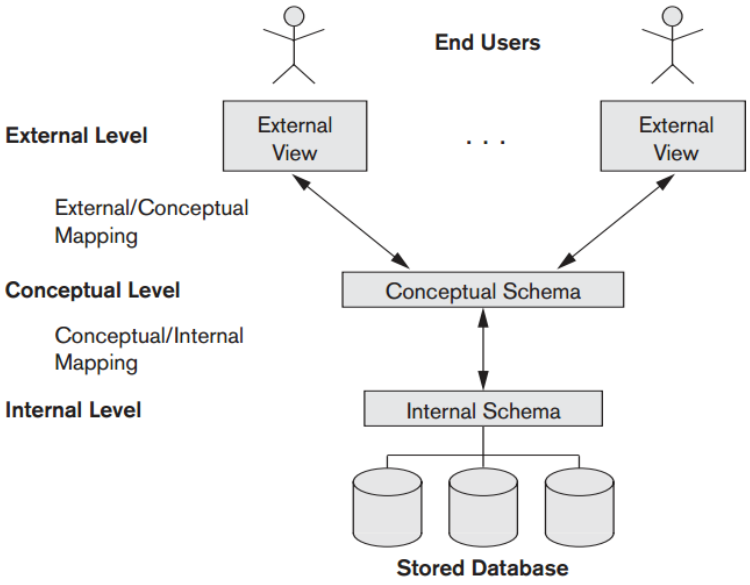

数据独立性(Data Independence)

逻辑数据独立性(logical data independence)

- 当概念模式发生改变时，只需修改外模式到概念模式的映射
- 外模式无需改变，依据外模式开发的应用程序也无需改变

物理数据独立性(physical data independence)

- 当内模式发生改变时，只需修改概念模式到内念模式的映射
- 概念模式和外模式均无需改变，依据外模式开发的应用程序也无需改变

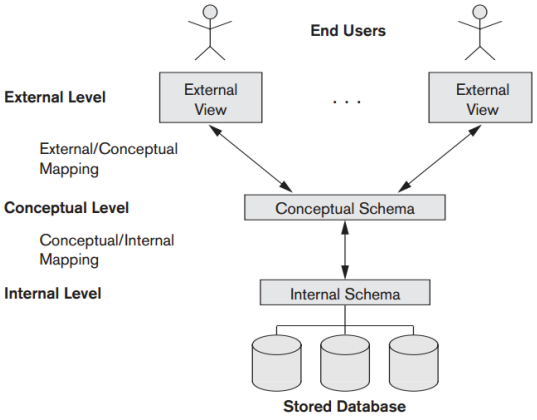

1.4 Database Languages

数据库语言(Database Language)

数据库语言(database language)是用户/应用程序与DBMS交互时所使用的语言

- 数据定义语言(data definition languages, DDL): DBA和数据库设计者用来声明数据库模式的语言
- 数据操纵语言(data manipulation languages, DML): 查询和更新数据库时所使用语言

第3章学习关系数据库结构化查询语言SQL

数据库查询(Database Queries)

- DML通常是描述式的(descriptive)，用它编写的数据库查询只描述查询意图，而不指明查询执行过程
- DBMS自动生成最优的查询计划，然后在数据库上执行查询计划

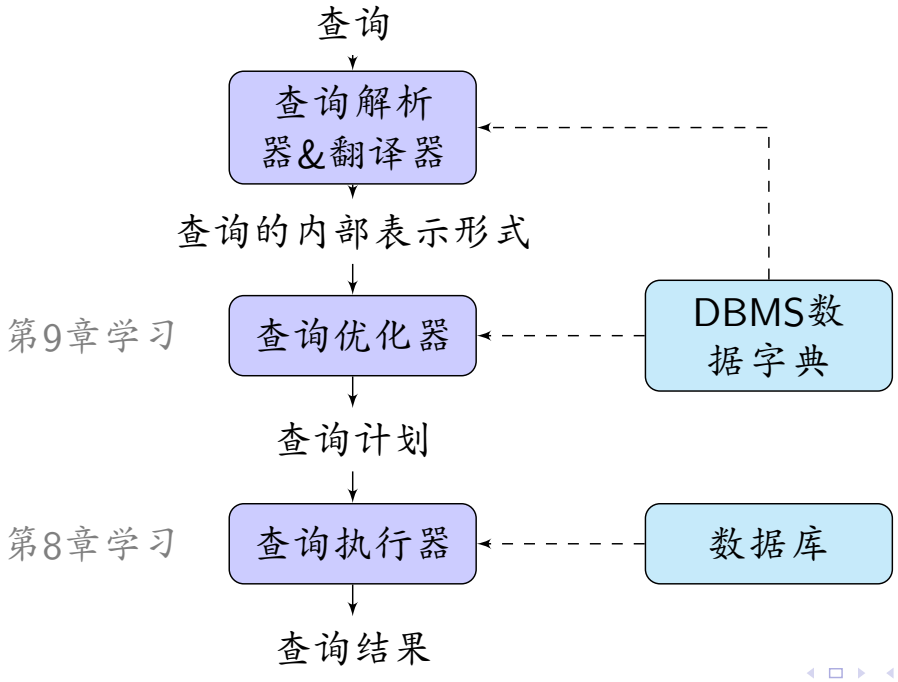

1.5 Index Structures

索引(Index)

- 索引(index)能够帮助DBMS快速找到关系中满足搜索条件的元组
- 索引对于提高查询处理效率至关重要

Example (索引)

索引

Sname	元组地址
Abby	$addr_3$
Ed	$addr_2$
Elsa	$addr_1$
Nick	$addr_4$

地址
$addr_1$
$addr_2$
$addr_3$
$addr_4$

Student关系

Sno	Sname	Ssex	Sage	Sdept
CS-001	Elsa	F	19	CS
CS-002	Ed	M	19	CS
MA-001	Abby	F	18	Math
PH-001	Nick	M	20	Physics

查询: `SELECT Sdept FROM Student WHERE Sname = 'Elsa';`

- 如果没有索引，则只能通过扫描Student关系来完成查询
- 如果有上述索引，则可以通过该索引来快速完成查询

索引的构成

- 索引键(index key): 索引根据一组属性(索引键)来定位元组
- 索引记录了元组的索引键值与元组地址的对应关系
- 索引项(index entry): 索引中的(键值，地址)对
- 索引中的索引项按索引键值排序

Example (索引)

索引

Sname	元组地址
Abby	$addr_3$
Ed	$addr_2$
Elsa	$addr_1$
Nick	$addr_4$

地址
$addr_1$
$addr_2$
$addr_3$
$addr_4$

Student关系

Sno	Sname	Ssex	Sage	Sdept
CS-001	Elsa	F	19	CS
CS-002	Ed	M	19	CS
MA-001	Abby	F	18	Math
PH-001	Nick	M	20	Physics

1.6 Transaction Processing

事务(Transaction)

事务(transaction)是由数据库上的一系列操作完成的复杂任务，这些操作要么全执行，要么全不执行

- 银行转帐
- 在线购物
- 会议室预定

事务的性质

- 原子性(atomicity)
- 一致性(consistency)
- 隔离性(isolation)
- 持久性(durability)

并发控制(Concurrency Control)

- 为了充分利用数据库系统，允许多个事务在数据库上并发执行
- 多个事务并发执行可能会破坏数据库的一致性

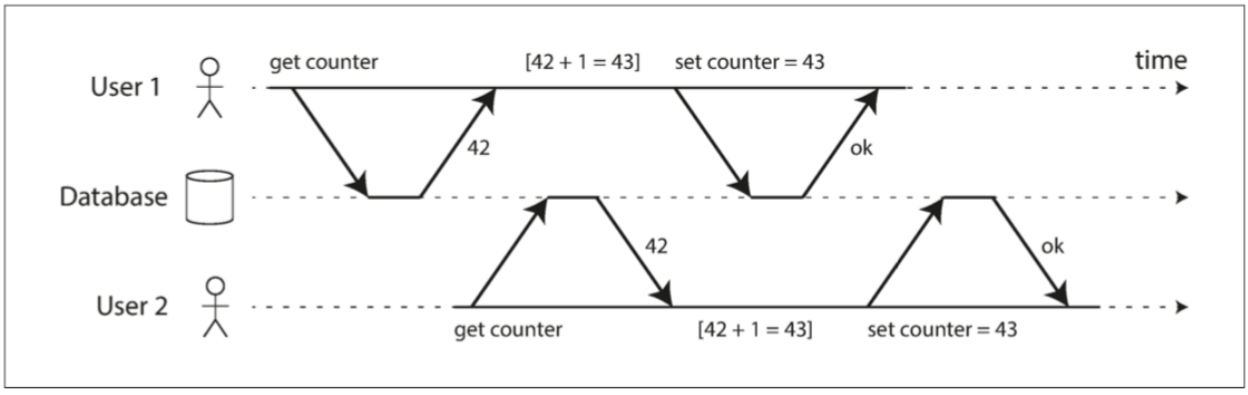

并发控制(concurrency control)确保多个事务并发执行不会破坏破坏数据库的一致性(第11章学习)

故障恢复(Failure Recovery)

- 计算机软硬件系统随时可能发生故障
- 故障可能在事务执行过程中间发生，从而破坏数据库的一致性
  - 例: 转账过程中系统发生故障
- 故障恢复(failure recovery)确保系统重启后数据库可以恢复到最近的一致性状态(第10章学习)

1.7 Architecture of a DBMS

DBMS的架构

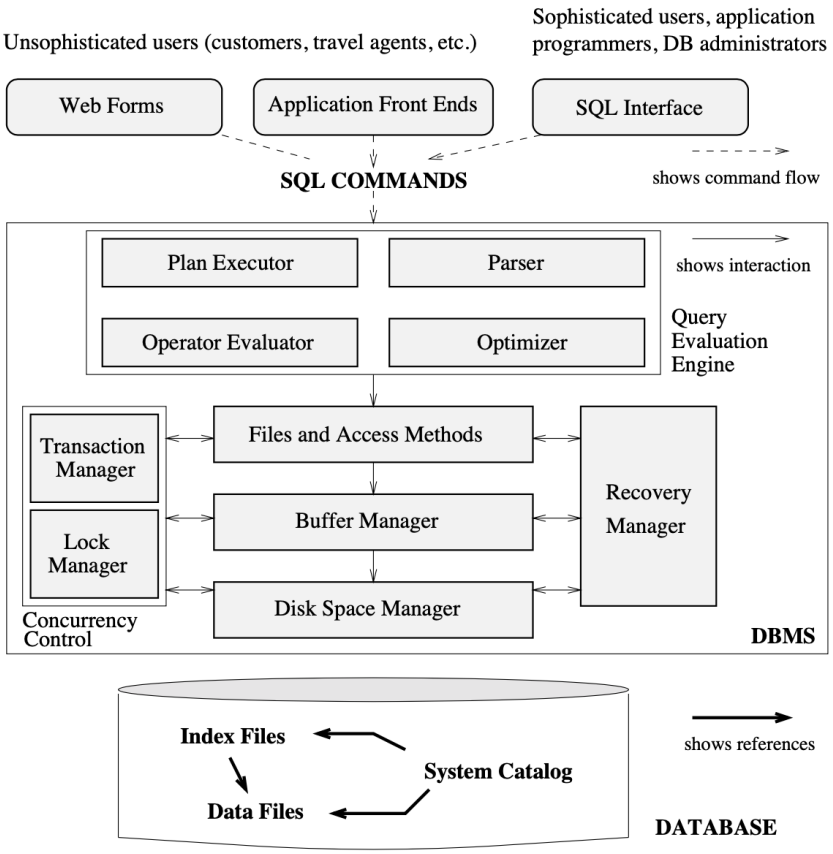

总结

1. 什么是数据管理?
2. 数据库系统的基本概念
3. 数据库系统的宝贵知识财富
   - 数据独立性
   - 数据库语言
   - 索引结构
   - 事务处理
4. 数据库管理系统的组成